

Pemanfaatan Ekstraksi Fitur k-mer dan Logistic Regression dalam Klasifikasi Promoter pada Sekuens DNA dan RNA

Muhamad Hasbullah Faris¹, Nazwan Siddqi Muttaqin², Matthew Sebastian Kurniawan³

¹Sekolah Teknik Elektro dan Informatika Institut Teknologi Bandung, Kota Bandung, 40132, email: 18223014@std.stei.itb.ac.id

²Sekolah Teknik Elektro dan Informatika Institut Teknologi Bandung, Kota Bandung, 40132, email: 18223066@std.stei.itb.ac.id

³Sekolah Teknik Elektro dan Informatika Institut Teknologi Bandung, Kota Bandung, 40132, email: 18223096@std.stei.itb.ac.id

INTISARI — Analisis sekuens DNA dan RNA, khususnya dalam pengidentifikasian region promoter, merupakan hal penting untuk memahami regulasi ekspresi gen tanpa harus selalu bergantung pada eksperimen biologis secara langsung. Namun, sekuens promoter memiliki pola yang tidak sederhana, sehingga diperlukan metode komputasi untuk menganalisis dan mengklasifikasikan sekuens tersebut berdasarkan pola tertentu. Penelitian ini mengusulkan pengembangan sistem komputasi biologi berupa aplikasi berbasis Python dan Streamlit yang menggabungkan ekstraksi fitur k-mer dan algoritma Logistic Regression untuk mengklasifikasikan sekuens DNA ke dalam kelas promoter atau non-promoter. Selain fitur klasifikasi dan analisis biologis dasar, sistem ini juga dilengkapi dengan sequence alignment menggunakan algoritma Needleman-Wunsch serta analisis sensitivitas mutasi secara in-silico untuk menginterpretasikan posisi sekuens yang berpengaruh terhadap prediksi model. Hasil pengujian pada dataset[1] menunjukkan bahwa model yang dikembangkan mampu mengklasifikasikan sekuens secara efektif dengan tingkat akurasi, precision, recall, dan F1-score sebesar 0,84 (84%) pada data uji. Sistem ini menunjukkan potensi yang baik untuk digunakan sebagai baseline komputasional dalam mengeksplorasi sekuens DNA/RNA dan menganalisis promoter secara otomatis.

KATA KUNCI — *Klasifikasi Promoter, Sekuens DNA, Ekstraksi Fitur k-mer, Logistic Regression, Komputasi Biologi.*

I. PENDAHULUAN

A. LATAR BELAKANG

DNA dan RNA merupakan molekul biologis yang berperan penting dalam penyimpanan, pemrosesan, dan ekspresi informasi genetik. Dalam proses ekspresi gen, informasi pada DNA dapat ditranskripsi menjadi RNA dan kemudian diterjemahkan menjadi protein melalui proses translasi. Oleh karena itu, analisis sekuens DNA dan RNA menjadi salah satu bidang penting dalam komputasi biologi.

Salah satu bagian penting pada DNA adalah promoter, yaitu region DNA yang berperan dalam menginisiasi proses transkripsi. Promoter membantu menentukan apakah suatu gen dapat diekspresikan atau tidak. Identifikasi promoter secara komputasional menjadi penting karena dapat membantu memahami regulasi gen tanpa harus selalu melakukan eksperimen biologis secara langsung. Namun, sekuens promoter memiliki pola yang tidak selalu sederhana, sehingga diperlukan metode komputasi untuk menganalisis dan mengklasifikasikan sekuens DNA berdasarkan pola tertentu.

Pada proyek ini, dikembangkan sebuah aplikasi berbasis Python dan Streamlit untuk melakukan analisis sekuens DNA/RNA serta klasifikasi promoter DNA. Proyek ini menggunakan pendekatan ekstraksi fitur k-mer dan Logistic Regression untuk mengklasifikasikan sekuens DNA ke dalam kelas promoter atau non-promoter. Fitur-fitur tersebut sesuai dengan fokus proyek pada analisis sekuens DNA/RNA dan sequence alignment.

B. KONSEP BIOLOGI TERKAIT

Konsep biologi utama yang digunakan dalam proyek ini adalah analisis sekuens DNA dan RNA. Sekuens DNA terdiri

atas kombinasi basa A, C, G, dan T, sedangkan RNA terdiri atas A, C, G, dan U. Perbedaan urutan basa dapat mempengaruhi fungsi biologis suatu region genom, termasuk apakah region tersebut berperan sebagai promoter atau bukan.

Promoter merupakan bagian DNA yang berada di sekitar awal gen dan berfungsi sebagai tempat pengikatan RNA polimerase serta faktor transkripsi. Keberadaan promoter sangat penting karena menentukan awal proses transkripsi dari DNA menjadi RNA, sehingga klasifikasi promoter dapat membantu memahami kemungkinan suatu sekuens DNA terlibat dalam regulasi ekspresi gen.

Selain promoter, proyek ini juga menggunakan konsep central dogma dan mutasi. Dalam central dogma, DNA ditranskripsi menjadi RNA, kemudian RNA diterjemahkan menjadi protein berdasarkan kodon. Sementara itu, mutasi merupakan perubahan pada sekuens DNA atau RNA, seperti substitusi, insersi, atau delesi, yang dapat menyebabkan perubahan hasil translasi protein seperti silent mutation, missense mutation, nonsense mutation, atau frameshift.

C. METODE KOMPUTASI TERKAIT

Metode komputasi utama yang digunakan dalam proyek ini adalah ekstraksi fitur k-mer. k-mer merupakan potongan substring sepanjang k dari suatu sekuens DNA atau RNA. Dalam proyek ini, k-mer digunakan untuk mengubah sekuens DNA yang berbentuk teks menjadi fitur numerik berupa jumlah kemunculan pola tertentu, sehingga dapat diproses oleh model machine learning.

Setelah fitur k-mer diperoleh, sistem menggunakan Logistic Regression untuk melakukan klasifikasi sekuens DNA ke

dalam kelas promoter atau non-promoter. Logistic Regression dipilih karena sederhana, efisien, dan sesuai untuk tugas klasifikasi biner. Input dari model berupa vektor jumlah k-mer, sedangkan output-nya berupa prediksi kelas serta probabilitas apakah suatu sekuens termasuk promoter atau non-promoter.

Selain klasifikasi, proyek ini juga menggunakan algoritma Needleman-Wunsch untuk sequence alignment dan fitur mutation sensitivity analysis untuk interpretasi model. Needleman-Wunsch digunakan untuk membandingkan dua sekuens secara global dengan menghitung kesesuaian, perbedaan, dan gap antar sekuens. Sementara itu, mutation sensitivity analysis dilakukan dengan membuat mutasi satu basa secara in-silico pada setiap posisi DNA, kemudian menghitung perubahan probabilitas promoter untuk melihat posisi yang paling mempengaruhi prediksi model.

D. TINJAUAN PUSTAKA DAN KARYA TERKAIT

Analisis sekuens DNA dan RNA merupakan salah satu penerapan penting dalam bidang bioinformatika. Salah satu pendekatan umum dalam pemrosesan sekuens biologis adalah representasi berbasis k-mer, karena mampu menangkap pola lokal pada sekuens tanpa memerlukan pemahaman struktur biologis yang terlalu kompleks. Dengan mengubah sekuens menjadi kumpulan k-mer, data biologis berbentuk teks dapat direpresentasikan sebagai fitur numerik untuk keperluan analisis komputasi.

Dalam klasifikasi sekuens biologis, metode machine learning dapat digunakan untuk mengenali pola pada data DNA. Logistic Regression merupakan salah satu metode klasifikasi biner yang dapat digunakan sebagai model dasar karena sederhana, mudah diinterpretasikan, dan cukup efektif sebagai baseline awal. Pada proyek ini, Logistic Regression digunakan untuk membedakan sekuens promoter dan non-promoter berdasarkan pola k-mer.

Selain klasifikasi, proyek ini juga menggunakan sequence alignment dan dataset promoter sebagai bagian dari proses analisis. Algoritma Needleman-Wunsch digunakan untuk membandingkan dua sekuens secara global, khususnya dalam analisis perbedaan antara sekuens referensi dan sekuens mutan. Dataset yang digunakan adalah dataset nukleotida yang dapat diakses pada [1], yang digunakan untuk melatih dan menguji model klasifikasi promoter tanpa menggunakan data sintesis pada proses training maupun evaluasi.

E. RUMUSAN MASALAH

Berdasarkan latar belakang tersebut, rumusan masalah dalam proyek ini adalah sebagai berikut.

1. Bagaimana mengembangkan aplikasi komputasi biologi yang dapat menganalisis sekuens DNA dan RNA secara dasar ?
2. Bagaimana menerapkan ekstraksi fitur k-mer untuk merepresentasikan sekuens DNA dalam bentuk numerik ?

3. Bagaimana menggunakan Logistic Regression untuk mengklasifikasikan sekuens DNA sebagai promoter atau non-promoter ?
4. Bagaimana menganalisis pengaruh mutasi titik terhadap probabilitas prediksi promoter yang dihasilkan oleh model ?
5. Bagaimana perbandingan sekuens normal dan mutan menggunakan analisis mutasi dan sekuens alignment ?

F. TUJUAN PENELITIAN

Tujuan dari proyek ini adalah sebagai berikut.

1. Mengembangkan aplikasi berbasis Python dan Streamlit untuk analisis sekuens DNA/RNA.
2. Mengimplementasikan fitur analisis biologis dasar, seperti validasi sekuens, komposisi basa, GC content, transkripsi, translasi, dan deteksi ORF.
3. Membangun model klasifikasi promoter DNA menggunakan ekstraksi fitur k-mer dan Logistic Regression.
4. Mengevaluasi performa model menggunakan data uji promoter dan non-promoter.
5. Mengimplementasikan analisis mutasi dan sequence alignment untuk membandingkan sekuens referensi dan sekuens mutan.
6. Menambahkan analisis sensitivitas mutasi untuk membantu menginterpretasikan posisi sekuens yang berpengaruh terhadap prediksi model.

II. METODE

A. ALUR SISTEM


Alur sistem pada proyek ini dimulai dari input berupa dataset promoter_all atau sekuens DNA/RNA yang dimasukkan oleh pengguna. Setelah input diterima, sistem melakukan validasi sekuens untuk memastikan bahwa karakter basa yang digunakan sesuai dengan jenis sekuens DNA atau RNA. Jika sekuens tidak valid, sistem akan menampilkan pesan error. Jika sekuens valid, sistem melanjutkan proses ke tahap analisis fitur biologis.

Pada tahap analisis fitur biologis, sistem menghitung beberapa informasi dasar dari sekuens, seperti komposisi basa, GC content, AT/AU content, dan k-mer. Setelah itu, alur sistem terbagi menjadi dua, yaitu mode training dan mode penggunaan aplikasi. Pada mode training, sistem melakukan ekstraksi fitur k-mer menggunakan CountVectorizer, melatih model Logistic Regression, mengevaluasi model pada data uji, lalu menyimpan model, vectorizer, dan metrik evaluasi.

Pada mode penggunaan aplikasi, hasil analisis sekuens ditampilkan melalui antarmuka Streamlit. Jika input berupa sekuens DNA, sistem melakukan ekstraksi fitur k-mer dari sekuens input, kemudian memprediksi apakah sekuens tersebut termasuk promoter atau non-promoter. Sistem juga menampilkan probabilitas prediksi promoter. Jika pengguna menjalankan analisis sensitivitas mutasi, sistem membuat mutasi titik secara in-silico, menghitung perubahan

probabilitas promotor, dan menentukan posisi yang paling sensitif terhadap prediksi model.

Selain klasifikasi promotor, sistem juga menyediakan fitur tambahan berupa mutation explainer dan sequence alignment. Mutation explainer digunakan untuk menganalisis perubahan antara sekuens normal dan mutan, sedangkan sequence alignment digunakan untuk membandingkan kemiripan antar sekuens. Alur lengkap sistem ditunjukkan pada Gambar dibawah ini.



Gambar 1. Flowchart alur sistem analisis sekuens DNA/RNA dan klasifikasi promotor DNA.

B. DATASET DAN VALIDASI SEKUENS

Dataset yang digunakan dalam proyek ini berasal dari hugging face dengan task promotor_all dan dapat diakses pada [1]. Dataset ini berisi sekuens DNA yang telah diberi label sebagai promotor atau non-promotor. Label 0 merepresentasikan sekuens non-promotor, sedangkan label 1 merepresentasikan sekuens promotor. Data yang digunakan dibagi menjadi data latih dan data uji berdasarkan split resmi, sehingga proses training dan evaluasi dilakukan menggunakan dataset yang terpisah.

Sebelum digunakan, dataset divalidasi untuk memastikan struktur dan isi datanya sesuai dengan kebutuhan sistem. Setiap data harus memiliki kolom sequence, label, task, dan name. Selain itu, sistem memastikan bahwa nilai label hanya berupa 0 atau 1, task yang digunakan adalah promotor_all, serta sekuens hanya mengandung karakter basa DNA yang valid, yaitu A, C, G, T, atau N. Validasi ini dilakukan agar model dilatih menggunakan data yang konsisten dan sesuai dengan konteks klasifikasi promotor DNA.

Pada sisi aplikasi, validasi juga dilakukan terhadap sekuens yang dimasukkan oleh pengguna. Sistem membersihkan input terlebih dahulu, misalnya mengubah huruf menjadi kapital dan

menghilangkan spasi yang tidak diperlukan. Setelah itu, sistem mendeteksi apakah input termasuk DNA, RNA, ambiguous, atau invalid. Sekuens DNA divalidasi berdasarkan karakter A, C, G, T, dan N, sedangkan sekuens RNA divalidasi berdasarkan karakter A, C, G, U, dan N. Jika input mengandung karakter yang tidak sesuai, sistem akan menampilkan pesan error dan analisis tidak dilanjutkan.

C. METODE KOMPUTASI

Metode komputasi utama yang digunakan dalam proyek ini adalah ekstraksi fitur k-mer dan klasifikasi menggunakan Logistic Regression. k-mer merupakan potongan substring sepanjang k dari suatu sekuens DNA. Dalam proyek ini, nilai default yang digunakan adalah $k = 6$. Setiap sekuens DNA diubah menjadi kumpulan k-mer, kemudian frekuensi kemunculan setiap k-mer dihitung menggunakan CountVectorizer. Hasil dari proses ini adalah vektor numerik yang dapat digunakan sebagai input model machine learning.

Setelah fitur k-mer diperoleh, sistem menggunakan model Logistic Regression untuk melakukan klasifikasi biner. Model ini digunakan untuk membedakan sekuens DNA ke dalam dua kelas, yaitu 0 sebagai non-promotor dan 1 sebagai promotor. Logistic Regression dipilih karena sederhana, efisien, dan sesuai digunakan sebagai baseline model untuk tugas klasifikasi. Output dari model berupa label prediksi serta probabilitas apakah suatu sekuens termasuk promotor atau non-promotor.

Selain klasifikasi, sistem juga melakukan mutation sensitivity analysis untuk membantu interpretasi hasil prediksi. Pada proses ini, sistem membuat mutasi titik secara in-silico pada setiap posisi sekuens DNA, kemudian menghitung kembali probabilitas promotor dari sekuens mutan. Perubahan probabilitas antara sekuens asli dan sekuens mutan digunakan untuk melihat posisi yang paling sensitif terhadap prediksi model. Hasil analisis ini bersifat interpretasi komputasional terhadap model, bukan validasi biologis eksperimental.

D. ANALISIS TAMBAHAN DAN KOMPONEN SISTEM

Selain klasifikasi promotor, sistem juga menyediakan beberapa fitur analisis tambahan untuk mendukung pemahaman terhadap sekuens DNA/RNA. Fitur transkripsi digunakan untuk mengubah DNA menjadi RNA, sedangkan fitur translasi digunakan untuk menerjemahkan RNA atau DNA menjadi urutan asam amino. Sistem juga menyediakan deteksi Open Reading Frame (ORF) untuk mencari kemungkinan region sekuens yang dapat diterjemahkan menjadi protein.

Sistem juga memiliki fitur mutation explainer dan sequence alignment. Mutation explainer digunakan untuk membandingkan sekuens normal dan sekuens mutan, serta mengidentifikasi jenis perubahan seperti substitusi, insersi, delesi, silent mutation, missense mutation, nonsense mutation, atau frameshift. Sequence alignment menggunakan algoritma Needleman-Wunsch untuk membandingkan dua sekuens secara

Komponen utama yang digunakan dalam proyek ini meliputi Python sebagai bahasa pemrograman utama, Streamlit sebagai antarmuka aplikasi, Pandas untuk pemrosesan data, Scikit-learn untuk ekstraksi fitur dan model Logistic Regression, Joblib untuk menyimpan model, serta Matplotlib untuk visualisasi hasil evaluasi.

III. HASIL DAN DISKUSI


Evaluasi kuantitatif dilakukan untuk mengukur performa model Logistic Regression berbasis fitur k-mer dalam mengklasifikasikan sekuens DNA sebagai promotor atau non-promotor. Model diuji menggunakan data uji dari dataset promotor_all dengan total 1584 sekuens, yang terdiri atas 792 sekuens non-promotor dan 792 sekuens promotor. Hasil evaluasi menunjukkan bahwa model memperoleh accuracy sebesar 0,84, sehingga sekitar 84% data uji berhasil diklasifikasikan dengan benar.

Gambar 2. Classification report hasil evaluasi model Logistic Regression berbasis k-mer pada data uji dataset promoter_all.

	0 non-promoter	1 promoter
0 non-promoter	661	131
1 promoter	129	663

Berdasarkan confusion matrix, terdapat 661 sekuens non-promoter yang berhasil diprediksi dengan benar sebagai non-promoter dan 663 sekuens promoter yang berhasil diprediksi dengan benar sebagai promoter. Sementara itu, terdapat 131 sekuens non-promoter yang salah diprediksi sebagai promoter dan 129 sekuens promoter yang salah diprediksi sebagai non-promoter. Hasil ini menunjukkan bahwa model memiliki kemampuan klasifikasi yang cukup baik dan relatif seimbang, meskipun masih terdapat kesalahan prediksi pada kedua kelas. Secara keseluruhan, pendekatan ekstraksi fitur k-mer dan Logistic Regression dapat digunakan sebagai baseline komputasional untuk klasifikasi promoter DNA.

Hasil kualitatif dari sistem ditunjukkan melalui fitur analisis sekuens DNA/RNA pada aplikasi Streamlit. Pada Gambar 4, pengguna memasukkan sekuens DNA/RNA ke dalam aplikasi melalui halaman Sequence Analysis. Pada tahap ini, sistem menerima input sekuens yang kemudian akan diproses lebih lanjut untuk menghasilkan berbagai informasi biologis dasar dan hasil analisis lanjutan.



Analysis record: sequence_1

Loaded read fast map: chr23.17610000-176130000 [total:1]


DNA sequence with length 300, GC content 45.33%, and ATAG content 54.67%.

Type	Length	GC content	ATAG content
DNA	300	45.33%	54.67%

Base composition


base	count	percentage
A	63	21.00
T	61	20.33
G	75	25.00
C	61	20.33
N	0	0.00

Gambar 5. Hasil analisis utama sekuens DNA/RNA yang menampilkan tipe sekuens, panjang sekuens, GC content, AT/AU content, komposisi basa, dan visualisasi distribusi basa.



Gambar 6. Hasil analisis lanjutan berupa top k-mers dan motif hits pada sekuens input.

Selain itu, sistem juga menampilkan hasil Open Reading Frame (ORF), transkripsi, dan translasi, sebagaimana ditunjukkan pada Gambar 7. Fitur ORF digunakan untuk mengidentifikasi bagian sekuens yang berpotensi diterjemahkan menjadi protein, sedangkan fitur transkripsi menunjukkan perubahan sekuens DNA menjadi RNA. Setelah itu, sistem juga menampilkan hasil translasi untuk menunjukkan kemungkinan urutan asam amino yang dihasilkan dari sekuens tersebut. Secara kualitatif, hasil-hasil ini menunjukkan bahwa sistem tidak hanya memberikan prediksi promotor atau non-promotor, tetapi juga menyediakan informasi biologis pendukung yang membantu pengguna memahami karakteristik dan fungsi sekuens yang dianalisis.



Gambar 7. Hasil transkripsi, translasi, dan Open Reading Frame (ORF) dari sekuens DNA yang dianalisis.

C. ANALISIS HASIL DALAM KONTEKS BIOLOGI

Berdasarkan hasil evaluasi, model klasifikasi promotor DNA memperoleh akurasi sebesar 0,84 dengan performa yang relatif seimbang pada kelas promotor dan non-promotor. Hal ini menunjukkan bahwa pola lokal pada sekuens DNA, yang direpresentasikan melalui fitur k-mer, dapat digunakan untuk membantu membedakan region promotor dan non-promotor. Dalam konteks biologi, promotor merupakan bagian DNA yang berperan dalam menginisiasi proses transkripsi, sehingga perbedaan susunan basa pada region tersebut dapat memengaruhi karakteristik sekuens yang dikenali oleh model.

Hasil analisis sekuens pada aplikasi juga memberikan informasi biologis pendukung terhadap sekuens yang dianalisis. Pada contoh hasil pengujian, sistem mendeteksi input sebagai sekuens DNA dengan panjang 300 basa, GC content sebesar 45,33%, dan AT/AU content sebesar 54,67%.

Nilai GC content dan AT/AU content membantu menggambarkan komposisi basa pada sekuens, sedangkan hasil top k-mers menunjukkan pola substring yang sering muncul. Pola-pola lokal seperti ini penting karena dapat menjadi bagian dari karakteristik sekuens yang digunakan model dalam proses klasifikasi promotor.

Selain itu, hasil deteksi motif, ORF, transkripsi, dan translasi menunjukkan bahwa sistem tidak hanya melakukan klasifikasi secara komputasional, tetapi juga menghubungkan hasil analisis dengan konsep biologi molekuler. Deteksi motif seperti ATG dan TAA dapat membantu mengidentifikasi bagian sekuens yang berkaitan dengan awal dan akhir translasi, sedangkan fitur transkripsi menunjukkan perubahan DNA menjadi RNA. Fitur ORF dan translasi juga memberikan gambaran kemungkinan region sekuens yang dapat diterjemahkan menjadi protein.

Secara keseluruhan, hasil yang diperoleh menunjukkan bahwa sistem dapat digunakan sebagai alat eksplorasi awal untuk analisis sekuens DNA/RNA dan klasifikasi promotor DNA. Namun, hasil prediksi dan analisis sensitivitas mutasi tetap bersifat komputasional. Posisi atau pola sekuens yang dianggap penting oleh model tidak dapat langsung dianggap sebagai motif biologis yang tervalidasi secara eksperimen, melainkan hanya menunjukkan hubungan antara pola k-mer dan prediksi model pada data yang digunakan.

IV. KESIMPULAN DAN SARAN

A. KESIMPULAN

Berdasarkan proses implementasi dan pengujian yang telah dilakukan pada sistem analisis sekuens DNA/RNA dan klasifikasi promotor DNA, dapat ditarik beberapa kesimpulan sebagai berikut.

- Sistem komputasi biologi berbasis Python dan Streamlit telah berhasil dikembangkan untuk melakukan analisis sekuens DNA/RNA. Sistem ini mampu menjalankan beberapa fitur utama, seperti validasi sekuens, analisis komposisi basa, perhitungan GC content, ekstraksi k-mer, transkripsi, translasi, ORF detection, mutation explainer, sequence alignment, serta klasifikasi promotor DNA.
- Model klasifikasi promotor menggunakan ekstraksi fitur k-mer dan Logistic Regression berhasil digunakan untuk membedakan sekuens DNA promotor dan non-promotor. Berdasarkan hasil evaluasi, model memperoleh akurasi sebesar 0,84 dengan nilai precision, recall, dan F1-score yang relatif seimbang pada kedua kelas. Hal ini menunjukkan bahwa pola lokal pada sekuens DNA dapat digunakan sebagai fitur komputasional untuk klasifikasi promotor.
- Fitur mutation sensitivity analysis memberikan kontribusi tambahan dalam bentuk interpretasi hasil prediksi model. Fitur ini memungkinkan sistem melihat pengaruh mutasi titik terhadap probabilitas promotor, sehingga pengguna dapat mengetahui posisi sekuens yang paling sensitif menurut model. Namun, hasil interpretasi tersebut tetap bersifat komputasional dan tidak dapat langsung dianggap

sebagai motif promotor yang telah tervalidasi secara biologis.

B. SARAN

Berdasarkan batasan sistem yang ada saat ini, terdapat beberapa saran pengembangan yang dapat dilakukan untuk menyempurnakan aplikasi ke depannya.

- Pengembangan model klasifikasi dapat dilakukan dengan mencoba metode machine learning lain, seperti Support Vector Machine, Random Forest, atau model berbasis deep learning. Perbandingan beberapa model dapat membantu mengetahui metode yang paling sesuai untuk klasifikasi promotor DNA berdasarkan fitur sekuens.
- Eksperimen terhadap variasi nilai k pada ekstraksi k-mer juga dapat dilakukan untuk melihat pengaruh panjang pola lokal terhadap performa model. Selain itu, penggunaan dataset yang lebih luas dan beragam dapat membantu meningkatkan kemampuan model dalam mengenali karakteristik promotor dari berbagai jenis organisme.
- Fitur interpretasi seperti mutation sensitivity analysis dapat dikembangkan lebih lanjut dengan membandingkan hasilnya terhadap motif promotor yang telah diketahui secara biologis. Dengan demikian, hasil interpretasi model tidak hanya menunjukkan sensitivitas komputasional, tetapi juga dapat dianalisis lebih lanjut dalam konteks biologi molekuler.

DAFTAR PUSTAKA

- [1] InstaDeepAI, “nucleotide_transformer_downstream_tasks_revised,” Hugging Face Datasets. Accessed: May 20, 2026. [Online]. Available: https://huggingface.co/datasets/InstaDeepAI/nucleotide_transformer_downstream_tasks_revised
- [2] L. A. Urry, M. L. Cain, S. A. Wasserman, P. V. Minorsky, and R. B. Orr, Campbell Biology in Focus, 3rd ed. New York, NY, USA: Pearson, 2020.
- [3] P. J. A. Cock et al., “Biopython: freely available Python tools for computational molecular biology and bioinformatics,” Bioinformatics, vol. 25, no. 11, pp. 1422–1423, 2009, doi: 10.1093/bioinformatics/btp163.
- [4] Streamlit Inc., “Streamlit: A faster way to build and share data apps,” Streamlit. Accessed: May 20, 2026. [Online]. Available: <https://streamlit.io>

LAMPIRAN

Kode program dan video demonstrasi proyek ini dapat diakses melalui tautan berikut:

Link Repository GitHub :

<https://github.com/NazwanSM/KDS-Sekuens-DNA-RNA>

Link Video YouTube:

https://youtu.be/sA5CBu-ZgN0?si=EFwbEEpTPkOcl_o8